Entrega Final: Cuadro comparativo y matriz de costos

1. Cuadro comparativo: modelo por tarea

Tarea del flujo	Qué uso	Por qué
Leer y clasificar cada correo nuevo con el RAG (spam / soporte / lead)	Claude con llamada normal a la API	Es lectura densa y el resultado se necesita en minutos
Generar el borrador de respuesta	Claude con llamada normal a la API	El cliente espera respuesta rápida
Reclasificar la bandeja histórica o procesar muchos correos acumulados	API de lotes (Batches)	No es urgente y el Batch API procesa en un máximo de 24 horas con un 50% de descuento en todos los tokens

2. Cálculo de tokens (valores de ejemplo)

Aplico Fórmula:

tokens de entrada = prompt del sistema + correo + fragmentos del RAG. Tokens de salida = respuesta del agente.

A. Con RAG (una sola consulta por correo)

- Entrada: 800 (prompt) + 500 (correo) + 1.200 (3 fragmentos del RAG) = **2.500**
- Salida: **150**

B. Con RAG e iteraciones (el agente consulta el RAG 3 veces)

En cada vuelta se reenvía todo lo anterior, por eso la entrada crece:

Iteración	Entrada	Salida
1	1.300	50
2	1.750	50
3	2.200	150
Total	**5.250**	**250**

Observación: Las iteraciones duplican aproximadamente el consumo de tokens por correo.

3. Costo y ahorro estimado

Escenario	Costo por correo	Costo mensual normal	Costo mensual con Batches	Ahorro
A. RAG simple	$0,0098	$97,50	$48,75	$48,75 (50%)
B. RAG con iteraciones	$0,0195	$195,00	$97,50	$97,50 (50%)